

Definition AGI

Die Evolution der LLMs

AGI: Artificial General Intelligence

- -> Besitzt intellektuelle Fähigkeiten wie ein Mensch (in allen Bereichen)
- -> kann sich selbst optimieren, kommunizieren, vorausschauend Planen etc.
- ->können Menschen eigenständig übertreffen und könnten die letzte Erfindung der Menschheit werden

Existenzielle Risiken

Übernahme kritischer Systeme

Könnten eigenen Nutzen Folgen zum Schaden der Menschheit

- -> Nick Bostrom (Oxford University): "Alignment Problem" Kompetent aber nicht "Gut"
- -> Stuart Russel, Elon Musk, Deepmind, OpenAl warnen vor existentieller Bedrohung
- ->Bsp. Paperclip Maximiser

Fehlende Regulierung

Entwicklung unbeaufsichtigt

Das Machtpotenzial kann von jedem uneingeschränkt (aus)genutzt werden

- -> KI-Act EU: erste Schritte die Weltweit nicht anerkannt oder unterbunden werden
- -> "Whistleblower-Berichte": Entwickler erhalten Warnungen welche ignoriert werden
- -> Bsp. KI lernt Menschen zu täuschen

Alignment Problem

Ausrichtung der Kls

Ausrichten sodass sie IMMER im Interesse der Menschen handeln nicht möglich

- -> Stuart Russell (UC Berkeley): "...keine Methode, um eine AGI sicher zu bauen"
- -> Forschung dazu steht am Anfang, bekommt kaum Fördergelder

Bsp. Halluzinieren der LLMs

Ökonomische Disruption

Arbeitsplatz Verlust

Wird Millionen von Jobs kosten

- -> Goldman Sachs (2023) schätzte: "bis zu 300 Mio. Jobs Weltweit" sind ersetzbar
- -> OECD: auch hoch Qualifizierte Jobs wie juristische Analyse und Softwareentwicklung

Bsp. ChatGPT etc. ersetzen jetzt schon Illustratoren und Entwickler

Machtkonzentration

Unternehmen bauen Monopole

Größere Modelle werden von großen Konzernen kontrolliert

- -> digitales Machtmonopol
- -> Training von zB. Gemini benötigt Milliarden, nicht für kleinere Konzerne möglich
- -> Daten und Rechenleistung sind in "Big Tech" zentralisiert, "KI-Oligarchie"
- Bsp. OpenAl war NonProfit jetzt: wenig Transparenz in Vorgehen

Missbrauch

Diktaturen, Kriminelle und Co.

KI kann leicht unethisch eingesetzt werden: Überwachung, Propaganda, Cyberangriffe

- -> China: Geschichtserkennung, soziale Kontrolle und Überwachung von Minderheiten
- -> Deepfakes: Wahlen oder Rufmordkapagnen durch "Videos"

Bsp. Wahlkampf 2024 "Fake-Obama" und Falschinformationen verbreitet

FazitStärkere Kontrollen

Fehlende Kontrolle:

- -> gezieltes Schaden und Machtmissbrauch von Seiten der AGI
- -> Sozialsystem kann mit der Entwicklungsgeschwindigkeit nicht mithalten
- -> Prävention ist effektiver als Katastrophenbewältigung
- -> sicheres Design ist Hybris

Wir sind nicht Gott, AGI könnte die letzte Erfindung der Menschheit sein!